FIAP · GLOBAL SOLUTION 2026.2

# VigiaVia GenAI
# Relatório técnico final

Generative AI for Engineering | Versão V4.6 | 11 de novembro de 2026

Extensão de IA local do VigiaVia para interpretação documental, consulta de relatos de mobilidade urbana, triagem assistida e explicações com rastreabilidade.

## 01 Equipe e identificação

| Integrante | RM |
|---|---|
| **Deivison Pertel** | 550803 |
| **Eduardo Akira Murata** | 98713 |
| **Wesley Souza de Oliveira** | 97874 |

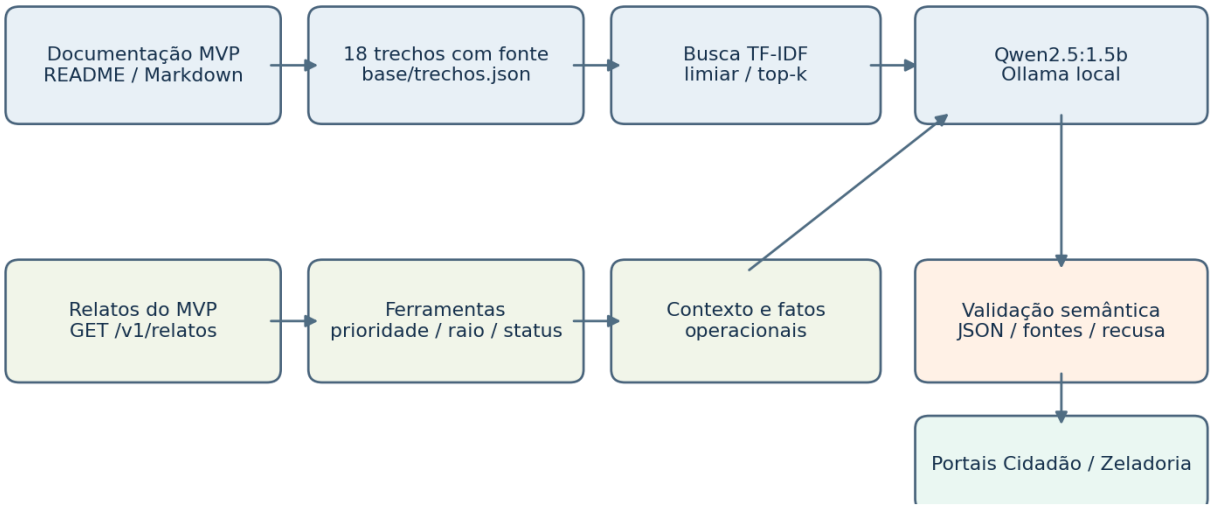
## 02 Ficha técnica — problema e solução

Problema: buracos em vias urbanas aumentam riscos e custos; o registro manual pode ser demorado, duplicado ou de difícil priorização. A extensão GenAI procura tornar dados e documentação compreensíveis para cidadãos e zeladoria.

Públicos: cidadãos (incluindo pedestres, ciclistas e motoristas) e equipe de zeladoria. Cenário de demonstração: Bela Vista, São Paulo; os nove relatos DEMO são inteiramente simulados.

| Componente | Implementação / responsabilidade |
|---|---|
| **Detecção visual (MVP)** | YOLO26n/ONNX Runtime; mAP@0,5 de 0,585 segundo documentação do MVP (não é métrica da LLM). |
| **LLM e execução** | Qwen2.5:1.5b local no Ollama, sem ajuste de pesos (sem LoRA). |
| **Especialização** | Agente com recuperação TF-IDF, seleção de fonte, validação semântica, citações e recusa. |
| **Aplicação** | FastAPI com portais Cidadão e Zeladoria. Integração read-only por GET /v1/relatos. |
| **Governança** | JSON e origem da informação; validação humana. Sem criação de chamados, reparos ou alteração automática de status. |

## 03 Diagrama do pipeline de IA e documentação




Fluxo documental: seções do README original → curadoria em 18 trechos → busca TF-IDF e calibração do limiar → Qwen2.5 local → verificação da resposta, citações e possibilidade de recusa. Fluxo operacional: API do MVP (somente leitura) ou DEMO → fatos e indicadores calculados por ferramenta → contexto do agente → resposta revisável.

Separação de dados: o RDD2022 é empregado no detector visual do MVP; não compõe a base RAG textual. Fatos do modo DEMO nunca devem ser apresentados como ocorrências reais.

## 04 Base de conhecimento — fontes, formatos, licenças e trechos

Base armazenada em base/trechos.json. O formato de origem é README em Markdown; os trechos do RAG estão em JSON. Licença informada abaixo corresponde à anotação presente nos metadados da base.

| Fonte (seção do README) | Origem → RAG | Licença declarada | Trechos |
|---|---|---|---|
| **Ficha técnica** | MD → JSON | AGPL-3.0 | 8 |
| **Arquitetura** | MD → JSON | AGPL-3.0 | 4 |
| **Segurança e lgpd** | MD → JSON | AGPL-3.0 | 3 |
| **Como executar** | MD → JSON | AGPL-3.0 | 1 |
| **Custos** | MD → JSON | AGPL-3.0 | 1 |
| **Licença** | MD → JSON | AGPL-3.0 | 1 |
| **TOTAL** | | | 18 |

Cada trecho contém id, titulo, fonte, url, licenca e texto; total de 18 IDs (V01–V18). URLs específicas e relação completa por seção constam no README do GitHub.

## 05 Desempenho das configurações testadas

Avaliação real com Qwen2.5:1.5b local: 18 questões por configuração (13 respondíveis e 5 com recusa esperada). A classificação de acerto abaixo é revisão do núcleo factual do gabarito, não simples contagem de citações nem uma auditoria externa independente.

| Configuração | Acerto revisado | Recusas indevidas | Com fontes | Latência média |
|---|---|---|---|---|
| **Baseline** | 5/18 · 27,8% | 12 | 0 | 597 ms |
| **RAG simples** | 11/18 · 61,1% | 2 | 11 | 1.220 ms |
| **Agente V4.6** | 13/18 · 72,2% | 5 | 8 | 1.298 ms |

Todos tiveram 5/5 recusas esperadas. O agente supera RAG simples em acertos na amostra, mas aumenta recusas indevidas (5 vs. 2), trade-off relevante. Respostas com fontes podem continuar erradas e devem ser lidas caso a caso.

### Busca e limiar

Com limiar TF-IDF de 0,19, recall@1 = 7/13 (53,85%) e recall@3 = 7/13 (53,85%). Na calibração a 0,16, recall@1 e recall@3 = 12/13 (92,31%), mas há perda de seletividade; a escolha do limiar deve equilibrar recuperação e recusa segura. A calibração foi feita sobre 13 questões respondíveis e 5 casos sem resposta.

### Validação dos portais

Execução V4.6 com dados de demonstração: 5/5 cenários atendidos no Cidadão e 5/5 na Zeladoria, incluindo recusas adequadas. Em Z03, o Ollama respondeu “A consulta contém 9 relato(s).”, com geração da LLM identificada como verdadeira e citação FILA. A triagem identifica DEMO-007 como possível duplicidade de DEMO-001, sem afirmar confirmação automática.

## 06 Cinco erros reais — causa e correção proposta

| ID | Falha observada | Causa identificada / provável | Correção / melhoria |
|---|---|---|---|
| **T03** | Respondeu sobre origem dos dados, não fluxo de detecção. | Busca selecionou V05 em vez de V03. | Roteamento temático e evidência decisiva V03. |
| **T05** | Respondeu só com link ou recusou. | Geração não cobriu as três fontes relevantes. | Exigir RDD2022, relatos dos cidadãos e DEMO simulada na revisão. |
| **T09** | Omitiu política de logs / recusou. | Não respondeu ambos os tópicos da pergunta. | Usar V09 e verificar “sem imagens armazenadas” + 30 dias de logs. |
| **T10** | Afirmou login obrigatório ou recusou. | Falha de negação; contradição com V10. | Bloqueio de contradição; extração identificada quando a LLM falhar. |
| **T11** | Negou transferência ou recusou incompleto. | Falha de polaridade e cobertura de V11. | Confirmar Nominatim fora do Brasil e alternativas mapa/GPS. |

Limitações adicionais observadas na V4.6: recusas indevidas em T01 e T13. As correções são incrementais e não eliminam a necessidade de revisão humana. A documentação das rodadas inclui sucessos, falhas e casos de regressão.

## 07 Conclusão técnica, reprodutibilidade e links

O VigiaVia GenAI demonstra que uma LLM pequena, local e especializada por agente pode oferecer explicações documentais e operacionais úteis, auditáveis por fontes e apoiadas por ferramentas. Na amostra de 18 casos, o agente atingiu 72,2% de acerto revisado, ante 61,1% do RAG simples e 27,8% do baseline. O resultado não comprova segurança ou generalização fora da amostra. As recusas indevidas, a variabilidade do modelo e a necessidade de autenticação para produção permanecem limitações.

Para reproduzir no Windows: criar venv Python 3.11, instalar requirements-dev.txt, executar ollama pull qwen2.5:1.5b, iniciar uvicorn app.main:app na porta 8001 e rodar pytest, avaliacao/medir.py, avaliacao/placar_llm.py e avaliacao/rodada_portais_ollama.py. A avaliação do Ollama sobrescreve saídas: preservar os JSONs originais.

Repositório do MVP original: https://github.com/akiramrt/vigiavia-mvp

### Evidências anexadas ao pacote do projeto

avaliacao/placar_real.json (avaliação V4.6); avaliacao/rodada_portais_real.json (testes dos portais); avaliacao/resultados_busca.json; avaliacao/calibracao_limires.json; avaliacao/casos.json; base/trechos.json; testes unitários e histórico das rodadas 01–05. Os registros de avaliação real documentam a execução do Ollama; testes unitários não substituem essa evidência.